

Analyse de Données avec Python & Pandas

Mory Junior Meite

MSc Data & AI — Mines Paris-PSL

Deux études de cas :

- Building Energy Benchmarking — NYC Open Data
- Student Performance Factors — Analyse prédictive

Contexte & Objectifs

Exploration de deux datasets réels avec Python et Pandas pour produire des insights actionnables via l'analyse exploratoire de données (EDA).

Dataset 1 — Building Energy Benchmarking NYC

+14 000 bâtiments new-yorkais. Variables : surface, type, énergie consommée, GHG.

Source : NYC Open Data (2016).

Dataset 2 — Student Performance Factors

Facteurs influençant les performances académiques : heures d'étude, sommeil, activité physique, accès aux ressources, résultats.

Méthodologie

1. Chargement & Exploration

Lecture CSV, audit des types, statistiques descriptives.

2. Nettoyage des données

Gestion des valeurs manquantes, outliers, normalisation, encodage.

3. Analyse Exploratoire (EDA)

Histogrammes, boxplots, heatmaps de corrélation, distributions.

4. Insights & Conclusions

Variables les plus corrélées, recommandations basées sur les données.

Stack Technique

Langage Python 3.x

Analyse Pandas · NumPy

Visualisation Matplotlib · Seaborn

Environnement Jupyter Notebook

Compétences mobilisées

- Manipulation avancée de DataFrames Pandas
- Nettoyage et préparation de données réelles
- Analyse statistique descriptive
- Data storytelling et visualisation